

Métodos Iterativos Line Search (continuação)

Otimização Não-Linear: métodos numéricos

ROSÁRIO D. LAUREANO

ISCTE-IUL Instituto Universitário de Lisboa
ISCTE-Sintra

- Problema de minimização livre/irrestrita: obter boas aproximações dos mínimos locais de uma função objetivo f , com variáveis de decisão $x \in \mathbb{R}^n$, $\min_x f(x) = ?$
- Métodos iterativos de busca em linha (*Line Search - LS*)
 - ▶ Método da Descida Máxima (*Steepest Descent Method - SDM*)
 - ▶ Método de Newton-Raphson (*Newton-Raphson Method - NRM*) entre outros
 - ★ Motivação, desenvolvimento e algoritmo ou pseudocódigo do método
 - ★ *m.file* com o código relativo ao método, *inputs* e ficheiros auxiliares
 - ▶ Discussão e comparação dos métodos estudados.

Table of Contents

- 1 Métodos iterativos de Busca em Linha (Line Search)
- 2 Método de Newton-Raphson (Newton-Raphson Method - NRM)

Table of Contents

1 Métodos iterativos de Busca em Linha (Line Search)

2 Método de Newton-Raphson (Newton-Raphson Method - NRM)

Métodos iterativos de Busca em Linha

- **Objetivo:** Obter soluções aproximadas x^* num problema de minimização $\min_x f(x) = ?$.
- Com métodos iterativos de **Busca em Linha** do tipo

$$x_{k+1} = x_k + \lambda_k \cdot d_k, \quad k = 0, 1, 2, \dots$$

a partir de um **ponto inicial/semente** x_0 (*seed*), onde $\lambda_k > 0$ é o **passo** (*stepsize*) e d_k é a **direção de busca** (*search direction*) na k -ésima iteração. A direção de busca d_k deve verificar a **condição de descida**

$$\underbrace{[\nabla f(x_k)]^T \cdot d_k}_{\text{número negativo}} < 0.$$

e é designada por **direções de descida** pois, para escolhas apropriadas de λ_k , obtemos em cada nova iterada um melhor valor de f , ou seja, $f(x_{k+1}) < f(x_k)$ (estamos num problema de minimização).

Métodos iterativos de Busca em Linha

A eficácia de um método de Busca em Linha exige que seja garantida a convergência (numérica) para 0 da sucessão de gradientes $\|\nabla f(x_k)\|$, $\|\nabla f(x_k)\| \rightarrow 0$ (com base na [Condição necessária de Otimalidade de 1ª ordem](#)).

Tal implica que (x_k) converge para um ponto crítico que pode ser um minimizante ou um ponto de sela, mas nunca um maximizante.

Como termina um método de Busca em Linha?

- Sempre que o algoritmo encontra uma solução;
- Sempre que é estabelecido um (ou +) [critério de paragem](#), ou seja, uma condição que force, quando necessário, o *terminus* do processo iterativo. Pode envolver uma limitação:
 - ▶ da norma do vetor gradiente: $\|\nabla f(x_k)\| < \epsilon$ para certo valor $\epsilon > 0$ designado por **tolerância**
 - ▶ (e/ou) do número de iterações $\text{MaxIter} \geq N$.

Quais os métodos que vamos estudar?

Apenas dois métodos de Busca em Linha:

- Método da Descida Máxima (*Steepest Descend Method - SDM*) (da "família", a família dos Métodos Gradiente) onde a direção de busca é



$$d_k = -\nabla f(x_k)$$

- Método de Newton-Raphson (*Newton-Raphson Method - NRM*) onde a direção de busca é

$$d_k = -[\nabla^2 f(x_k)]^{-1} \cdot \nabla f(x_k).$$

Escolha adequada do passo

Também a escolha do **passo em cada iteração** é importante:



No caso de curvas circulares, basta uma iteração qualquer que seja o passo.

(figuras de autor desconhecido)

Condições de Wolfe

As condições de Wolfe (baseadas no teorema de Zoutendijk) são relativas à escolha do passo (não constante) em cada iteração:

CONDIÇÕES de WOLFE. Definida a **função de penalidade**

$\phi(\lambda) := f(x_k + \lambda \cdot d_k)$, as condições de Wolfe são

$$\textbf{(W1)} \quad \phi(\lambda_k) \leq \phi(0) + c_1 \cdot \lambda_k \cdot \phi'(0)$$

e

$$\textbf{(W2)} \quad \phi'(\lambda_k) \geq c_2 \cdot \lambda_k \cdot \phi'(0),$$

com $0 < c_1 < c_2 < 1$.

As condições **(W1)** e **(W2)** podem então ser escritas como

$$\textbf{(W1)} \quad f(x_k + \lambda_k \cdot d_k) \leq f(x_k) + c_1 \cdot \lambda_k \cdot [\nabla f(x_k)]^T \cdot d_k$$

e

$$\textbf{(W2)} \quad [\nabla f(x_k + \lambda_k \cdot d_k)]^T \cdot d_k \geq c_2 \cdot [\nabla f(x_k)]^T \cdot d_k.$$

Table of Contents

1 Métodos iterativos de Busca em Linha (Line Search)

2 Método de Newton-Raphson (Newton-Raphson Method - NRM)

Método de Newton-Raphson

O **método de Newton-Raphson** é, na sua forma geral, usado na resolução numérica de equações do tipo

$$F(x) = 0$$

para funções $F = (f_1, f_2, \dots, f_n) : \mathbb{R}^n \rightarrow \mathbb{R}^n$ de classe C^1 .

Necessário ao desenvolvimento que fundamenta este método, note que o gradiente do campo de vetores F é a função

$\nabla F = (\nabla f_1, \nabla f_2, \dots, \nabla f_n) : \mathbb{R}^n \rightarrow \mathcal{M}_{n \times n}$ cujas componentes são os campos gradientes de cada uma das funções componentes de F .

Como usar o método de Newton-Raphson em problemas de minimização?

Com base na **Condição Necessária de Otimalidade de 1ª ordem**, este método pode ser aplicado, em particular, para determinar os pontos críticos de uma função objetivo $f : \mathbb{R}^n \rightarrow \mathbb{R}$ de classe C^2 : tomamos nesse caso $F(x) = \nabla f(x)$ para resolver a equação estacionária

$$\nabla f(x) = 0.$$

Método de Newton-Raphson: fundamentos

Voltemos ao método de Newton-Raphson na sua forma geral, para resolver equações $F(x) = 0$.

- Dado uma estimativa x_k para a solução de $F(x) = 0$, o método de Newton-Raphson resulta de considerar a aproximação linear de Taylor

$$F(x_{k+1}) = F(x_k + d_k) \approx F(x_k) + [\nabla F(x_k)]^T \cdot d_k.$$

- Sempre que $\nabla F(x_k)$ é regular, o determinante da matriz $[\nabla F(x_k)]^T$ é diferente de 0 e existe a sua matriz inversa.
- Uma nova estimativa de solução para $F(x) = 0$ resulta de resolver a equação

$$F(x_k) + [\nabla F(x_k)]^T \cdot d_k = 0,$$

onde resulta a direção de busca do método de Newton-Raphson

$$d_k = - \left[[\nabla F(x_k)]^T \right]^{-1} \cdot F(x_k).$$

Método de Newton-Raphson: Q-convergência

A eficiência do método de Newton-Raphson é garantida pelo teorema seguinte que garante a sua convergência:

Teorema. Seja $F = (f_1, f_2, \dots, f_n) : \mathbb{R}^n \rightarrow \mathbb{R}^n$ de classe C^1 num aberto U que contenha uma solução x^* da equação $F(x) = 0$ (ou seja, $F(x^*) = 0$) onde o gradiente $\nabla F(x^*)$ é regular.

Então existe um conjunto aberto S contendo x^* tal que as iterações do método de Newton-Raphson estão bem definidas, permanecem em S e convergem de forma **Q-superlinear** para x^* (ver aula 11)

PROVA: consulte NR na Secção 3 do ficheiro de demonstrações de complemento aos slides.

NOTA: Se F for de classe C^1 , embora seja suficiente que ∇F seja Lipschitz, então a convergência do método de Newton-Raphson é **Q-quadrática**.

Método de Newton-Raphson em otimização

Para efeitos de minimização, se o método de Newton-Raphson é usado na determinação dos pontos críticos de uma função objetivo $f : \mathbb{R}^n \rightarrow \mathbb{R}$ de classe C^2 , a direção de busca já referida, $d_k = - \left[[\nabla F(x_k)]^T \right]^{-1} \cdot F(x_k)$, passa a envolver a matriz Hessiana de f tomando a forma

$$d_k = - \left[[\nabla^2 f(x_k)]^T \right]^{-1} \cdot \nabla f(x_k), \quad (1)$$

visto que $F = \nabla f$. Temos então a regra de iteração

$$x_{k+1} = x_k + \lambda_k \cdot \left[- \left[(\nabla^2 f(x_k))^T \right]^{-1} \cdot \nabla f(x_k) \right], \quad k = 0, 1, 2, \dots$$

a partir de um pto inicial/semente x_0 , onde $\lambda_k > 0$ é o passo.

Quando associada ao passo constante $\lambda_k = 1$, esta direção de busca d_k é designada por **direção de Newton**. Este passo pode não garantir uma melhoria efetiva da função objetivo mas, à falta de mais informação, é sempre considerado, por exemplo para a inicialização β_0 do Algoritmo 1 (ver Secção 2 do ficheiro dedemonstrações de complemento aos slides).

Método de Newton-Raphson: limitações

Embora o método de Newton-Raphson seja muito utilizado pela sua rápida convergência, superior à do método de Descida Máxima, ele também apresenta **algumas limitações**:

- A direção de Newton é, do ponto de vista computacional, bastante exigente, por implicar o cálculo de derivadas de 2ª ordem e a resolução de um sistema.
- Se a matriz Hessiana $\nabla^2 f$ não for definida positiva então não há razão para esperar que a direção de Newton seja efetivamente uma direção de descida, ou seja, que verifique a condição $[\nabla f(x_k)]^T \cdot d_k < 0$. Concretamente,
 - ▶ é frequente não ser convergente para mínimos e, em particular,
 - ★ se $\nabla^2 f$ é definida negativa então o método pode convergir rapidamente para máximos.
- a convergência é **local**: só está garantida mediante uma boa escolha do ponto inicial x_0 (ou seja, uma boa estimativa inicial).

Método de Newton-Raphson: melhoria de convergência

No entanto, nas condições do teorema de Zoutendijk (anteriormente descrito), a convergência é global sempre que a função objetivo f seja uniformemente convexa, conforme a classificação que se segue quanto à convexidade (complementa o já abordado sobre Otimização Convexa).

Seja $f : \mathbb{R}^n \rightarrow \mathbb{R}$ de classe C^2 e $S \subseteq \mathbb{R}^n$ um conjunto convexo onde f esteja definida. Temos:

Convexidade:

$$f \text{ convexa sobre } S \Leftrightarrow \nabla^2 f(x) \succeq 0, \forall x \in S.$$

Convexidade estrita:

$$f \text{ estritamente convexa sobre } S \Leftrightarrow \nabla^2 f(x) \succ 0, \forall x \in S.$$

Convexidade uniforme:

$$f \text{ uniformemente convexa sobre } S \Leftrightarrow \exists \delta > 0 : \nabla^2 f(x) \succ \delta, \forall x \in S.$$