

Complemento aos slides da Aula 2 (Line-Search Methos)

¹Rosário D. Laureano
Iscte-Sintra
ISCTE-IUL Instituto Universitário de Lisboa

Este ficheiro complementa a Aula 2 (L-S): esclarece melhor a diferença entre os vários m.file, "contextualiza" os exercícios propostos (referenciados ao longo do texto) e apresenta elementos mais teóricos que esclarecem os slides (evidentemente + resumidos). O texto remete para ficheiros em MATLAB, mas serão fornecidos os respetivos em Python.

1. Sobre escolha de pontos iniciais

Os métodos de busca em linha (Line Search-LS) não têm, sem informação à priori rigorosa sobre a escolha de pontos iniciais x_0 , forma de evitar a convergência para mínimos locais e não para o mínimo absoluto. Por sua vez, em geral a informação à priori sobre a escolha de pontos iniciais x_0 é difícil de conseguir por impossibilidade de calcular os pontos críticos.

Para tornar mais provável a determinação do mínimo global, podemos iterar o método de busca em linha que estamos a usar (há muitos mais para além dos que estudámos...) para diversos pontos iniciais x_0 e tomar, no final, o melhor de todos os resultados (que são valores mínimos locais de f) obtidos para os diferentes pontos iniciais considerados. A escolha dos pontos iniciais pode ser feita de forma aleatória num intervalo

$$[a_1, b_1] \times \cdots \times [a_n, b_n] \subset \mathbf{R}^n.$$

Em MATLAB, dados $a = [a(i)]^T$ e $b = [b(i)]^T$, com $i = 1, \dots, n$, a **geração pseudo-aleatória** de um ponto inicial, com distribuição uniforme, pode ser feita por

$$x_0 = (b - a) .* rand(n, 1) + a.$$

No m.file [descidaMaximaV1aula.m](#) - onde foi implementado o Método de Descida Máxima (SDM - Steepest Descent Method) - foi introduzida esta geração pseudo-aleatória de um ponto inicial (Exercício 4 da Secção 3 do ficheiro de Exercícios Propostos). Caso contrário, o código no que respeita à escolha do ponto inicial poderia ser algo do tipo $x=[1.1,0.9]'$ (' para a transposta de uma matriz) correspondente a $x(1)=1.1$ e $x(2)=0.9$, conforme o m.file [descidaMaximaV0.m](#) usado no Exercício 3 da Secção 3 do ficheiro de Exercícios Propostos.

NOTA (relativa ao Método de Descida Máxima): a convergência para pontos de sela é improvável no SDM. De facto, dado um ponto de sela s^* de uma função objetivo $f : \mathbf{R}^n \rightarrow \mathbf{R}$ de classe C^2 com $\nabla^2 f(s^*)$ indefinida, existe $\varepsilon > 0$ tal que, escolhendo aleatoriamente pontos iniciais x_0 no intervalo $]-\varepsilon, \varepsilon[^n$, a probabilidade do Método de Descida Máxima gerar sequências convergentes para s^* é nula.

2. Sobre escolha de passos

A escolha dos passos deve prioritariamente potenciar uma redução substancial da função objectivo mas, simultaneamente, essa escolha deve ser simples e rápida.

No Método de Descida Máxima é frequente considerar passos constantes $\lambda_k = \lambda > 0$, por ser o mais imediato e simples. Mas este procedimento pode ser bastante inadequado: existem funções para as quais o este método com passos constantes λ gera, com probabilidade igual a 1, sequências de iteradas (x_k) que verificam $f(x_k) \rightarrow +\infty$ para pontos iniciais escolhidos aleatoriamente num qualquer intervalo limitado (conforme pode ser observado no Exercício 4 da Secção 3 do ficheiro de Exercícios Propostos).

Embora uma escolha de passos constante possa ser uma opção a ter em conta se, por exemplo, a avaliação da função objectivo f for demasiado "despendiosa" em termos computacionais, podemos ser mais criteriosos na escolha dos passos λ_k a fim de:

- garantir a **convergência do processo iterativo** para o mínimo global e/ou
- tornar essa convergência tão rápida quanto possível.

Para tal, após definida a direcção de busca d_k , a qual distingue os diferentes métodos de busca em linha, e que é

- $d_k = -\nabla f(x_k)$ no Método de Descida Máxima,
- $d_k = -[\nabla^2 f(x_k)]^{-1} \cdot \nabla f(x_k)$ no Método de Newton-Raphson (NRM),

introduzimos a **função de penalidade**

$$\phi(\lambda) := f(x_k + \lambda \cdot d_k).$$

que é uma função uni-variável na variável λ . Uma solução natural e óptima para a escolha dos passos λ_k seria então considerar, em cada iteração, o passo óptimo (caso exista) obtido como solução do problema de minimização

$$\lambda_k^* = \arg \min_{\lambda > 0} \phi(\lambda),$$

ou seja, minimizar a função de penalidade e tomar o passo λ_k como sendo o valor mínimo global λ_k^* dessa função.

Contudo, este método revela-se pouco eficiente pois o percurso mais rápido para o mínimo de f não é necessariamente determinado pelo valor mínimo global das sucessivas funções de penalidade ϕ . Por exemplo, dada a escolha aleatória do ponto inicial x_0 num intervalo limitado e dado $0 < \delta < 1$, é possível encontrar funções com um mínimo absoluto x^* , para as quais o Método de Descida Máxima gera, com probabilidade $1 - \delta$, sequências de iteradas (x_k) que convergem para mínimos locais (não globais), mesmo que a escolha de passos seja "óptima", isto é, seja usado $\lambda_k^* = \arg \min_{\lambda > 0} \phi(\lambda)$.

Além disso, é em geral demasiado "despendioso" determinar esse valor λ_k^* ; até mesmo encontrar um valor mínimo local de $\phi(\lambda) = f(x_k + \lambda \cdot d_k)$ com precisão moderada requer frequentemente uma séria avaliação da função objectivo f e do vector gradiente ∇f envolvido na definição da direcção de busca d_k quer no Método de descida máxima quer no Método de Newton-Raphson.

Como tal, foi necessário desenvolver algoritmos com critérios mais exequíveis para a determinação dos passos λ_k e que, mesmo assim, garantam boas propriedades de convergência do processo iterativo.

Um dos algoritmos a considerar é:

ALGORITMO 1 Escolher $\lambda_0 = 1$ e parâmetros $\rho, c \in]0, 1[$ e determinar o passo λ_k a partir de do passo λ_{k-1} através do seguinte processo iterativo, onde β_0 é uma função a ajustar conforme o método de busca em linha que está a ser usado, ou seja, conforme a direcção de busca escolhida:

Step 1: $\beta = \beta_0$

Step 2: **repetir enquanto**

$$\phi(\beta) > \phi(0) + c \cdot \beta \cdot \phi'(0) \quad (1)$$

$$\beta \leftarrow \rho\beta$$

fim da repetição

Step 3: $\lambda_k \leftarrow \beta$

Note que (1) é equivalente a considerar **repetir enquanto**

$$f(x_k + \beta \cdot d_k) > f(x_k) + c \cdot \beta \cdot [\nabla f(x_k)]^T \cdot d_k$$

e não esqueça que, em qualquer método de busca em linha, a escolha da direcção de busca d_k se baseia em garantir a condição de descida $[\nabla f(x_k)]^T \cdot d_k < 0$.

No m.file [descidaMaximaV3.m](#) está implementado o Método de Descida Máxima com escolha de passos segundo o Algoritmo 1. Este algoritmo está, por sua vez, implementado na subrotina [selPassosV0.m](#).

Embora não exista no Método de Descida Máxima uma escolha natural para o ponto inicial β_0 (ao contrário de outros métodos, como o de Newton-Raphson e suas versões e os métodos quasi-Newton), a especificação

$$\beta_0 = \lambda_{k-1} \frac{[\nabla f(x_{k-1})]^T \cdot d_{k-1}}{[\nabla f(x_k)]^T \cdot d_k}$$

é bastante usada e também está implementada na ficheiro [descidaMaximaV3.m](#). Quanto ao parâmetros ρ e c , os valores típicos são $\rho = 0.9$ e $c = 10^{-4}$.

Considere os [Exercícios 5 e 6](#) da Secção 3 do ficheiro de Exercícios Propostos para comparação da eficiência do novo processo de escolha dos passos λ_k com o de passos constantes λ , em termos da qualidade das aproximações obtidas e do número de iterações necessárias.

Para escolhas apropriadas dos passos, o Método de Descida Máxima gera sequências de iteradas convergentes. Assumindo este facto, e que a escolha de passos satisfaz $\lambda_k \leq \min \{ \lambda \geq 0 : \phi'(\lambda) = 0 \}$, é possível classificar, para muitas funções,

os pontos dos respectivos domínios enquanto pontos iniciais x_0 deste método que geram seqüências com o mesmo limite.

Contudo, a escolha dos passos pelo Algoritmo 1 não é 100% eficiente. Existem funções para as quais, mesmo com uma escolha de passos segundo este algoritmo, não se obtém $\|\nabla f(x_k)\| \rightarrow 0$ (em particular, com $f(x_k)$ decrescente). Ou seja, o Algoritmo 1 pode gerar seqüências de passos (λ_k) demasiado pequenas e cujos respectivos (x_k) não convergem para pontos críticos.

Para não permitir que os passos fiquem demasiado pequenos, garantindo boas propriedades de convergência, usamos as **condições de Wolfe** (contrárias a (1))

$$(W1) \quad \phi(\lambda_k) \leq \phi(0) + c_1 \cdot \lambda_k \cdot \phi'(0)$$

$$(W2) \quad \phi'(\lambda_k) \geq c_2 \cdot \lambda_k \cdot \phi'(0),$$

onde $0 < c_1 < c_2 < 1$.

Estas condições são, respectivamente, equivalentes a

$$(W1) \quad f(x_k + \lambda_k \cdot d_k) \leq f(x_k) + c_1 \cdot \lambda_k \cdot [\nabla f(x_k)]^T \cdot d_k$$

$$(W2) \quad [\nabla f(x_k + \lambda_k \cdot d_k)]^T \cdot d_k \geq c_2 \cdot [\nabla f(x_k)]^T \cdot d_k.$$

Se f é diferenciável e limitada inferiormente (ou seja, minorada) então, para cada escolha de direção de busca d_k , existe sempre um intervalo $I \subset \mathbf{R}^+$ onde as condições de Wolfe são satisfeitas.

O Algoritmo genérico seguinte permite, em situações favoráveis, determinar uma escolha de passos associada a três critérios de classificação: "Adequado", "Grande" e "Pequeno".

ALGORITMO 2

Step 1: Escolher $t > 0$ (à falta de melhor $t = 1$) e fixar $t_L = t_R = 0$.

Step 2: **Enquanto** $t_R = 0$, **se** t "Adequado" **terminar** algoritmo (**return**), **se** t "Grande" declarar $t_R = t$, **caso contrário** aumentar t (por exemplo: $t \leftarrow ct$, para $c > 1$).

Step 3: Escolher t em $]t_L, t_R[$ e testar t :

- se "Adequado" **terminar** algoritmo;
- se "Grande" declarar $t_R = t$;
- se "Pequeno" declarar $t_L = t$.

O Algoritmo 2 está implementado em [Wolfe.m](#), onde a escolha de passos satisfaz as condições de Wolfe considerando:

- "Adequado" a satisfação das condições de Wolfe;
- "Grande" a negação da 1ª condição de Wolfe;
- "Pequeno" a satisfação da 1ª condição de Wolfe e a negação da 2ª.

O correspondente ao Método de Descida Máxima está em [descidaMaximaWolfe.m](#).

3. Convergência global

Um método de busca em linha é eficaz se estiver garantida a convergência (numérica) da sucessão de gradientes $\|\nabla f(x_k)\|$ para 0, $\|\nabla f(x_k)\| \rightarrow 0$.

O resultado seguinte dá-nos um **critério geral de convergência global** para estes métodos, em termos do ângulo formado pela direção de busca d_k e a direção de descida máxima $-\nabla f(x_k)$, ou seja,

$$\cos(\theta_k) = \frac{-[\nabla f(x_k)]^T \cdot d_k}{\|\nabla f(x_k)\| \cdot \|d_k\|}.$$

Este critério conta ainda com a verificação das **condições de Wolfe**¹

$$(W1) \quad \phi(\lambda_k) \leq \phi(0) + c_1 \cdot \lambda_k \cdot \phi'(0) \quad (2)$$

$$(3)$$

$$(W2) \quad \phi'(\lambda_k) \geq c_2 \cdot \lambda_k \cdot \phi'(0), \quad (4)$$

onde $0 < c_1 < c_2 < 1$, sendo ϕ a função (unidimensional) de penalidade definida por $\phi(\lambda) := f(x_k + \lambda \cdot d_k)$.

Teorema de Zoutendijk Dada uma função $f : \mathbf{R}^n \rightarrow \mathbf{R}$, considere uma k -ésima iteração da forma (1), com ponto inicial $x_0 \in \mathbf{R}^n$, onde a direção de busca d_k satisfaz a condição de descida (2) e o passo $\lambda_k > 0$ satisfaz as condições de Wolfe (3) e (4). Suponhamos que f é limitada inferiormente (minorada) e diferenciável com gradiente uniformemente Lipschitz num aberto U que contem o conjunto de nível $\mathcal{L} = \{x \in \mathbf{R}^n : f(x) \leq f(x_0)\}$, ou seja, $\|\nabla f(x) - \nabla f(y)\| \leq L \|x - y\|, \forall x, y \in U$ para certo $L > 0$. Então a série $\sum_{k \geq 0} [\cos^2(\theta_k) \cdot \|\nabla f(x_k)\|]$ é convergente, ou seja, $\sum_{k \geq 0} [\cos^2(\theta_k) \cdot \|\nabla f(x_k)\|] < \infty$.

Nas condições do Teorema de Zoutendijk temos necessariamente $\cos^2(\theta_k) \cdot \|\nabla f(x_k)\| \rightarrow 0$ e, se as direções de busca d_k se mantiverem afastadas do espaço ortogonal a $-\nabla f(x_k)$ para k suficientemente grande, ou seja,

$$\cos(\theta_k) \geq \delta > 0, \quad (5)$$

então temos $\|\nabla f(x_k)\| \rightarrow 0$, conforme o pretendido em métodos iterativos de busca em linha.

Assim, o Teorema de Zoutendijk, complementado com a condição (5), constitui um **critério geral para convergência global**. Esta convergência é relativa à sucessão de gradientes $\nabla f(x_k)$, cuja norma está efetivamente a convergir para 0 mesmo que a sucessão

¹Como sabemos, estas condições são, respetivamente, equivalentes a

$$(W1) \quad f(x_k + \lambda_k \cdot d_k) \leq f(x_k) + c_1 \cdot \lambda_k \cdot [\nabla f(x_k)]^T \cdot d_k$$

$$(W2) \quad [\nabla f(x_k + \lambda_k \cdot d_k)]^T \cdot d_k \geq c_2 \cdot [\nabla f(x_k)]^T \cdot d_k.$$

associada (x_k) não seja convergente. O termo global caracteriza o facto das sucessões geradas serem convergentes para escolha de pontos iniciais x_0 . Esta noção difere da de convergência local onde a escolha de pontos iniciais x_0 tem de ser feita numa vizinhança suficientemente pequena de um ponto crítico para garantir a convergência.

Como consequência do critério geral para convergência global temos o seguinte corolário relativo ao método de descida máxima.

Convergência do Método de Descida Máxima Seja $f : \mathbf{R}^n \rightarrow \mathbf{R}$ uma função que satisfaz as condições anteriores. Então o Método de Descida Máxima com passos que satisfaçam as condições de Wolfa (3) e (4) gera sequências de iteradas (x_k) tais que $\nabla f(x_k) \rightarrow 0$.

Note que a sequência de iteradas (x_k) pode não convergir. Por exemplo, na aplicação do Método de Descida Máxima à função $f(x) = \exp(x)$ (que satisfaz as condições do Teorema de Zoutendijk) obtemos $x_k \rightarrow -\infty$.

A convergência do Método de Descida Máxima em condições tão gerais é um facto fundamental. No entanto, essa convergência deve ser qualificada quanto à velocidade, a fim de avaliar a concreta utilidade do ponto de vista numérico / computacional.

EXEMPLOS.

(1) A sequência $x_k = (1/2)^k = 12^k$ converge para 0 de forma Q-linear mas não de forma Q-superlinear.

(2) A sequência $x_k = k^{-k} = 1k^k$ converge para 0 de forma Q-superlinear mas não de forma Q-quadrática.

(3) A sequência $x_k = (1/2)^{2^k} = 12^{2^k}$ converge para 0 de forma Q-quadrática.

Temos as seguintes relações entre formas de Q-convergência:

$$Q - quadrática \Rightarrow Q - superlinear \Rightarrow Q - linear.$$

A convergência no Método de Descida Máxima é em geral lenta. Antes de apresentar o seguinte teorema relativo a este método, considere a definição de número de condição.

Dada uma matriz simétrica B definida positiva com valores próprios $p_1 \leq \dots \leq p_n$, (usamos p_i e não o usual λ_i para evitar confusão com a sequência dos passos), e considerando a norma euclidiana $\|\cdot\|$, temos $p_1 \cdot \|x\|^2 \leq x^T \cdot B \cdot x \leq p_n \cdot \|x\|^2$ e define-se o **número de condição de** B por $\kappa(B) := \|B\| \cdot \|B^{-1}\| = \frac{p_n}{p_1}$.

Suponha que $f : \mathbf{R}^n \rightarrow \mathbf{R}$ é uma função de classe C^2 e que a sequência de iteradas (x_k) dadas pelo Método de Descida Máxima, com escolha de passos óptima, ou seja, segundo

$$\lambda_k^* = \arg \min_{\lambda > 0} \phi(\lambda)$$

para a função de penalidade $\phi(\lambda) := f(x_k + \lambda \cdot d_k)$, converge para x^* , onde a matriz Hessiana $\nabla^2 f(x^*)$ é definida positiva. Então, para n suficientemente grande, temos

$$\|f(x_{n+1}) - f(x^*)\| \leq \left(\frac{\kappa - 1}{\kappa + 1}\right)^2 \|f(x_n) - f(x^*)\|,$$

onde κ é o número de condição da matriz $\nabla^2 f(x^*)$.

Este teorema mostra que a convergência Q-linear é a melhor que podemos esperar para Método de Descida Máxima, visto ser o tipo de convergência que se obtém para funções quadráticas.

4. Demonstração de resultados

NR Assumamos que $x_k \in S$ para todo o $k \leq m$, onde S é um conjunto a descrever ao longo da prova mas onde, desde já, o gradiente ∇F é regular.

Provemos por indução que também $x_{m+1} \in S$.

Denotando o resto (ou erro) da fórmula de Taylor de 1ª ordem por $R : \mathbf{R}^n \rightarrow \mathbf{R}^n$, temos

$$0 = F(x^*) = F(x_m) + [\nabla F(x_m)]^T \cdot (x^* - x_m) + R(x^* - x_m),$$

ou ainda,

$$0 = F(x_m) + [\nabla F(x_m)]^T \cdot x^* - [\nabla F(x_m)]^T \cdot x_m + R(x^* - x_m). \quad (6)$$

Visto que as iteradas do método de Newton-Raphson dadas pela direcção de busca

$$d_k = -[\nabla F(x_k)]^T^{-1} \cdot F(x_k)$$

satisfazem a equação

$$0 = F(x_m) + [\nabla F(x_m)]^T \cdot (x_{m+1} - x_m),$$

ou seja,

$$0 = F(x_m) + [\nabla F(x_m)]^T \cdot x_{m+1} - [\nabla F(x_m)]^T \cdot x_m, \quad (7)$$

segue, efectuando a diferença (1)-(2), que

$$0 = [\nabla F(x_m)]^T \cdot x^* - [\nabla F(x_m)]^T \cdot x_{m+1} + R(x^* - x_m).$$

Temos então

$$0 = [\nabla F(x_m)]^T \cdot (x^* - x_{m+1}) + R(x^* - x_m)$$

que implica a igualdade com normas

$$\|x^* - x_{m+1}\| = \left\| [\nabla F(x_m)]^T^{-1} \right\| \cdot \|R(x^* - x_m)\|.$$

Sendo M um majorante de $\left\| [\nabla F(x_m)]^T^{-1} \right\|$ no conjunto S , é válida a desigualdade

$$\|x^* - x_{m+1}\| \leq M \cdot \|R(x^* - x_m)\|. \quad (8)$$

Para $F \in C^1$, o resto $R(x^* - x_m)$ é um infinitésimo quando comparado com $x^* - x_m$, ou seja, $R(x^* - x_m) = o(x^* - x_m)$. Logo, para S uma vizinhança suficientemente pequena de x^* , temos

$$R(x^* - x_k) \leq \frac{1}{2M} \cdot \|x^* - x_k\|$$

para $k \leq m$. Obtemos então, de (3), que

$$\begin{aligned} \|x^* - x_{m+1}\| &\leq M \cdot \frac{1}{2M} \cdot \|x^* - x_m\| = \frac{1}{2} \cdot \|x^* - x_m\| \\ &\leq \left(\frac{1}{2}\right)^2 \cdot \|x^* - x_{m-1}\| \leq \left(\frac{1}{2}\right)^3 \cdot \|x^* - x_{m-2}\| \\ \dots &\leq \left(\frac{1}{2}\right)^{m-1} \cdot \|x^* - x_1\| \leq \left(\frac{1}{2}\right)^m \cdot \|x^* - x_0\|. \end{aligned}$$

Como $\left(\frac{1}{2}\right)^m \cdot \|x^* - x_0\| \rightarrow 0$ quando $m \rightarrow \infty$ também $\|x^* - x_{m+1}\| \rightarrow 0$. De

$$\|x^* - x_{m+1}\| \leq \frac{1}{2} \cdot \|x^* - x_m\|$$

concluimos que $x_{m+1} \in S$ e, por indução, todas as iteradas estão bem definidas e contidas em S .

Ainda de (3) concluimos que se $F \in C^1$ então a convergência é Q-superlinear. De facto, temos

$$R(x^* - x_m) = o(x^* - x_m).$$

E se $F \in C^2$ então a convergência é Q-quadrática pois, nesse caso, temos

$$\|R(x^* - x_m)\| \leq C \cdot \|x^* - x_m\|^2.$$

5. Métodos Quase-Newton

[Este conteúdo não foi tratado na UC] Os **métodos quasi-Newton** são métodos iterativos da forma

$$x_{k+1} = x_k - B_k^{-1} \cdot \nabla f(x_k),$$

onde $B_k \in \mathcal{M}(\mathbf{R})_{n \times n}$ são matrizes $n \times n$ definidas positivas (de entradas reais) a determinar em cada iteração.

A necessidade das matrizes B_k serem definidas positivas advém de se pretender métodos com a principal vantagem do Método de Newton-Raphson - a rápida convergência local - e que evitem ao máximo a sua principal desvantagem - a necessidade de calcular derivadas de 2ª ordem e a falta de convergência global.

Conforme verificámos anteriormente, se os números de condição² das matrizes B_k , denotados por $\kappa(B_k)$, forem limitados $\kappa(B_k) < M$, então o Teorema de Zoutendijk garante convergência global do respetivo método quasi-Newton.

Quanto à convergência local, temos uma generalização do Teorema (vamos referir como teorema NR) demonstrado na Secção anterior, que garante eficácia do Método de Newton Raphson (slides Aulas 5+6):

Teorema. Nas condições do Teorema NR existem números positivos $\varepsilon_x > 0$ e $\varepsilon_M > 0$ tais que, se $\|x_0 - x^*\| < \varepsilon_x$ e

$$\|B_k - F'(x_k)\| < \varepsilon_M, \forall k \geq 0,$$

então a sequência de iteradas resultantes de $x_{k+1} = x_k - B_k^{-1} \cdot \nabla f(x_k)$ está bem definida e é Q-linear convergente para x^* .

Se, além disso, as matrizes B_k convergem para $F'(x^*)$, $B_k - F'(x^*)$, então a convergência é Q-superlinear.

Finalmente, se F' é Lipschitz numa vizinhança de x^* e

$$B_k - F'(x^*) = \mathcal{O}(\|x_k - x^*\|^2)$$

então a convergência é Q-quadrática.

Consideremos um algoritmo que combina diretamente os métodos até agora estudados (da Descida Máxima e de Newton-Raphson) e que reúne as vantagens de ambos:

- a convergência global (embora lenta) do Método de Descida Máxima e
- a convergência rápida (embora local) do Método de Newton-Raphson.

ALGORITMO DE NEWTON MISTO

Se $\nabla^2 f(x_k) > 0$

então $d_k = -[\nabla^2 f(x_k)]^{-1} \cdot \nabla f(x_k)$ e λ_k determinado por busc em linha com inicialização $\beta_0 = 1$.

caso contrário $d_k = -\nabla f(x_k)$.

Ou seja,

Se $\nabla^2 f(x_k) > 0$

então a direção de busca d_k é a do N-R M e o passo λ_k é determinado por Line Search com inicialização $\beta_0 = 1$.

²Dada uma matriz simétrica B definida positiva com valores próprios $p_1 \leq \dots \leq p_n$, (usamos p_i e não o usual λ_i para evitar confusão com a sequência dos passos), e considerando a norma euclidiana $\|\cdot\|$, temos $p_1 \cdot \|x\|^2 \leq x^T \cdot B \cdot x \leq p_n \cdot \|x\|^2$ e define-se o **número de condição de B** por

$$\kappa(B) := \|B\| \cdot \|B^{-1}\| = \frac{p_n}{p_1}.$$

caso contrário a direção de busca d_k é a do Método de Descida Máxima.

Pode ser interessante a implementação do algoritmo anterior no MATLAB de duas formas distintas, a saber,

- testando o sinal da Hessiana $\nabla^2 f$
- testando apenas se a direção de Newton é ou não de descida, isto é, se $d_k = -[\nabla^2 f(x_k)]^{-1} \cdot \nabla f(x_k)$ verifica a condição de descida $[\nabla f(x_k)]^T \cdot d_k < 0$,

e analisar o desempenho computacional.

Podemos generalizar o método anterior considerando matrizes quasi-New-ton B_k que envolvam uma perturbação da matriz Hessiana com múltiplos $\mu_k \geq 0$ da matriz identidade I_n . Esta perturbação potencia a obtenção de uma matriz definida positiva que, como vimos, é essencial para garantir que as direções de busca d_k sejam de facto direções de descida. Trata-se de considerar B_k da forma

$$B_k = \nabla^2 f(x_k) + \mu_k \cdot I_n,$$

onde os escalares $\mu_k \geq 0$ são escolhidos de forma a garantir a condição de descida $[\nabla f(x_k)]^T \cdot d_k < 0$ que, neste caso, se traduz por

$$[\nabla f(x_k)]^T \cdot \underbrace{[\nabla^2 f(x_k) + \mu_k \cdot I_n]^{-1} \cdot \nabla f(x_k)}_{d_k} < 0.$$

A sequência de iteradas é então dada por

$$x_{k+1} = x_k - [\nabla^2 f(x_k) + \mu_k \cdot I_n]^{-1} \cdot \nabla f(x_k).$$

Podemos ainda considerar um processo iterativo decorrente desta última igualdade, ou seja, que envolva "passos",

$$x_{k+1} = x_k - \lambda_k \cdot [\nabla^2 f(x_k) + \mu_k \cdot I_n]^{-1} \cdot \nabla f(x_k),$$

onde os escalares $\mu_k \geq 0$ são escolhidos de forma a garantir a condição de descida $[\nabla f(x_k)]^T \cdot d_k < 0$ que, neste caso, se traduz por

$$[\nabla f(x_k)]^T \cdot \underbrace{[\nabla^2 f(x_k) + \mu_k \cdot I_n]^{-1} \cdot \nabla f(x_k)}_{d_k} > 0.$$

No entanto, se $\nabla^2 f(x_k) > 0$ então podemos tomar $\mu_k = 0$ e obter uma iteração de Newton "pura". Se $\nabla^2 f(x_k) \leq 0$ for regular então μ_k poderá ser da ordem de grandeza do módulo do menor valor próprio da matriz Hessiana. E para μ_k suficientemente grande aproximamo-nos do Método de Descida Máxima.

Proposição. Nas condições do Teorema de Zoutendijk, se $\nabla^2 f(x^*) > 0$ então existem escolhas $\mu_k \rightarrow 0$ e de $\lambda_k \rightarrow 1$ que garantem convergência global da sequência de iteradas dadas por

$$x_{k+1} = x_k - \lambda_k \cdot \left[\nabla^2 f(x_k) + \mu_k \cdot I_n \right]^{-1} \cdot \nabla f(x_k),$$

.

O mais popular dos métodos quasi-Newton é o **Método Broyden-Fletcher-Goldfarb-Shanno (BFGS)**. O objectivo inerente a este método é determinar a sucessão de matrizes B_k de forma a ser uma aproximação pelo menos assintótica (i.e., quando $k \rightarrow \infty$) da sequência de matrizes Hessianas, constituída por matrizes definidas positivas. Para restringir a busca, uma vez que para $f \in C^2$ temos

$$\nabla f(x_k) \approx \nabla f(x_{k+1}) + \nabla^2 f(x_{k+1}) \cdot (x_k - x_{k+1}),$$

ou seja,

$$\nabla f(x_k) - \nabla f(x_{k+1}) \approx \nabla^2 f(x_{k+1}) \cdot (x_k - x_{k+1})$$

se B_{k+1} é suposto aproximar $\nabla^2 f(x_{k+1})$ então é natural impor que

$$B_{k+1} \cdot (x_k - x_{k+1}) = \nabla f(x_k) - \nabla f(x_{k+1}).$$

Esta igualdade é usualmente escrita de forma mais simples como

$$B_{k+1} \cdot s_k = y_k$$

definindo $s_k := x_k - x_{k+1}$ e $y_k := \nabla f(x_k) - \nabla f(x_{k+1})$. A condição de definição das matrizes B_k , $B_{k+1} \cdot s_k = y_k$, diz-se **condição de secante** ou **condição quasi-Newton**.

Outra motivação para a escolha deste método (e que dá o nome à condição $B_{k+1} \cdot s_k = y_k$) é o método da secante que garante convergência Q-superlinear para as soluções da equação a uma variável $F(x) = 0$, onde $F : \mathbb{R} \rightarrow \mathbb{R}$ é uma função de classe C^1 . Dadas estimativas x_{k-1} e x_k para a solução, o método da secante determina uma nova estimativa igualando a 0 a aproximação dada pela respectiva secante, ou seja,

$$F(x) = \frac{F(x_k) - F(x_{k-1})}{x_k - x_{k-1}}x + (x - x_k).$$

Explicitando x_{k+1} obtemos uma expressão possível de relacionar com a condição de secante $B_{k+1} \cdot s_k = y_k$. A condição de secante garante que $s_k^T \cdot y_k > 0$.